

最小二乘法

张晓平

2016 年 11 月 15 日

给出 m 个点 t_1, \dots, t_m 和这 m 个点上的实验或观测数据 y_1, \dots, y_m , 并假定给出 t_i 上取值的 n 个已知函数 $\psi_1(t), \dots, \psi_n(t)$ 。考虑 ψ_i 的线性组合

$$f(x, t) = x_1\psi_1(t) + x_2\psi_2(t) + \dots + x_n\psi_n(t)$$

希望在 t_1, \dots, t_m 点上 $f(x, t)$ 能最佳地逼近这些数据 y_1, \dots, y_m 。

定义残量

$$r_i(x) = y_i - \sum_{j=1}^n x_j\psi_j(t_i), \quad i = 1, \dots, m \quad (1)$$

则问题成为：估计参数 x_1, \dots, x_n , 使残量 r_1, \dots, r_m 尽可能地小。

残量 (1) 的矩阵形式为

$$r(x) = b - Ax$$

其中

$$A = \begin{bmatrix} \psi_1(t_1) & \dots & \psi_n(t_1) \\ \vdots & \ddots & \vdots \\ \psi_1(t_m) & \dots & \psi_n(t_m) \end{bmatrix}, \quad b = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad r(x) = \begin{bmatrix} r_1(x) \\ \vdots \\ r_m(x) \end{bmatrix}.$$

- 当 $m = n$ 时, 可要求 $r(x) = 0$.
- 当 $m > n$ 时, 一般不可能使所有残量均为 0, 但可要求残向量在某种意义下达到最小。

最小二乘问题就是求 x 使残向量 $r(x)$ 在 2 范数意义下最小。

给定矩阵 $A \in \mathbb{R}^{m \times n}$ 及向量 $b \in \mathbb{R}^m$, 确定 $x \in \mathbb{R}^n$ 使得

$$\|r(x)\|_2 = \min_{y \in \mathbb{R}^n} \|r(y)\|_2 \quad (2)$$

该问题称为最小二乘问题 (LS, Least square)。最小二乘问题的解 x 又可称作


$$Ax = b, \quad A \in \mathbb{R}^{m \times n} \quad (3)$$

的最小二乘解，即 x 在残向量 $r(x) = b - Ax$ 的 2 范数最小的意义下满足 (3).

对于线性方程组 (3),

- 当 $m > n$ 时，称为超定方程组或矛盾方程组；
- 当 $m < n$ 时，称为欠定方程组。

最小二乘问题的几种情形



设 $A \in \mathbb{R}^{m \times n}$ ，定义 A 的值域为

$$\mathcal{R}(A) = \{y \in \mathbb{R}^m : y = Ax, x \in \mathbb{R}^n\}.$$

习题 1. $\mathcal{R}(A) = \text{span}\{a_1, \dots, a_n\}$, 其中 a_i 为 A 的列向量。

定义 A 的零空间为

$$\mathcal{N}(A) = \{x \in \mathbb{R}^n : Ax = 0\},$$

它的维数记为 $\text{null}(A)$.

定义一个子空间 $\mathcal{S} \in \mathbb{R}^n$ 的正交补为

$$\mathcal{S}^\perp = \{y \in \mathbb{R}^n : y^T x = 0, \forall x \in \mathcal{S}\},$$

定理 1. 线性方程组 (3) 的解存在的充分必要条件是

$$\text{rank}(A) = \text{rank}(A, b).$$




图 1: 几何解释 ($m = 3, \text{rank}(A) = 2$)

证明. (\Rightarrow) 设存在 x 使得 $Ax = b$, 则 b 是 A 的列向量的线性组合, 即有 $b \in \mathcal{R}(A)$, 这说明 $\mathcal{R}(A, b) = \mathcal{R}(A) \Rightarrow \text{rank}(A) = \text{rank}(A, b)$.

(\Leftarrow) 若 $\text{rank}(A, b) = \text{rank}(A)$ 成立, 则 $b \in \mathcal{R}(A)$, 即 b 可表示为

$$b = \sum_{i=1}^n x_i a_i$$

这里 $A = [a_1, \dots, a_n]$. 于是, 令 $x = (x_1, \dots, x_n)^T$, 即有 $Ax = b$. □

定理 2. 若线性方程组 (3) 的解存在, 且假定 x 是其任一给定的解, 则 (3) 的全部解的集合是

$$x + \mathcal{N}(A).$$

证明. 若 y 满足 (3), 则 $A(y - x) = 0$, 即 $y - x \in \mathcal{N}(A)$, 于是有 $y = x + (y - x) \in x + \mathcal{N}(A)$.

反之, 若 $y \in x + \mathcal{N}(A)$, 则存在 $z \in \mathcal{N}(A)$, 使 $y = x + z$, 从而有 $Ay = Ax + Az = Ax = b$. □

上述定理告诉我们, 只要知道线性方程组 (3) 的一个解, 便可以用它及 $\mathcal{N}(A)$ 中的向量得到 (3) 的全部解, 由此可知, (3) 的解要想唯一, 只有当 $\mathcal{N}(A)$ 中仅有零向量。

推论 1. 线性方程组 (3) 的解唯一的充分必要条件是 $\text{null}(A) = 0$ 。

定理 3. 线性最小二乘问题 (2) 的解总是存在的, 而且其解唯一的充分必要条件是 $\text{null}(A) = 0$ 。

证明. 因为 $\mathbb{R}^m = \mathcal{R}(A) \oplus \mathcal{R}(A)^\perp$, 所以 b 可唯一表示为

$$b = b_1 + b_2, \quad b_1 \in \mathcal{R}(A), \quad b_2 \in \mathcal{R}(A)^\perp.$$

于是 $\forall x \in \mathbb{R}^n, \mathcal{R}(A) \ni b_1 - Ax \perp b_2$, 从而

$$\|r(x)\|_2^2 = \|b - Ax\|_2^2 = \|(b_1 - Ax) + b_2\|_2^2 = \|b_1 - Ax\|_2^2 + \|b_2\|_2^2$$

由此可知, $\|r(x)\|_2^2$ 达到最小当且仅当 $\|b_1 - Ax\|_2^2$ 达到最小。而 $b_1 \in \mathcal{R}(A)$ 意味着 $\|b_1 - Ax\|_2^2$ 达到最小当且仅当 $Ax = b_1$ 。这样, 由 $b_1 \in \mathcal{R}(A)$ 和推论 1 可得定理结论。 \square

记最小二乘问题的解集为 \mathcal{X}_{LS} , 即

$$\mathcal{X}_{LS} = \{x \in \mathbb{R}^n : x \text{ 是 LS 问题 (2) 的解}\}.$$

由定理 3 知, \mathcal{X}_{LS} 非空, 且它仅有一个元素的充要条件是 A 的列向量线性无关。

定理 4. $x \in \mathcal{X}_{LS}$ 当且仅当

$$A^T Ax = A^T b. \quad (4)$$

证明. (\Rightarrow) 设 $x \in \mathcal{X}_{LS}$ 。由定理 3 的证明知 $Ax = b_1$, 其中 $b_1 \in \mathcal{R}(A)$, 且

$$r(x) = b - Ax = b - b_1 = b_2 \in \mathcal{R}(A)^\perp,$$

从而 $A^T r(x) = A^T b_2 = 0 \Rightarrow A^T Ax = A^T b$ 。

(\Leftarrow) 设 $x \in \mathbb{R}^n$ 满足 $A^T Ax = A^T b$, 则 $\forall y \in \mathbb{R}^n$,

$$\begin{aligned} \|b - A(x + y)\|_2^2 &= \|b - Ax\|_2^2 - 2y^T A^T (b - Ax) + \|Ay\|_2^2 \\ &= \|b - Ax\|_2^2 + \|Ay\|_2^2 \geq \|b - Ax\|_2^2. \end{aligned}$$

由此即得 $x \in \mathcal{X}_{LS}$ 。 \square

(4) 称为最小二乘问题

$$\|b - Ax\|_2 = \min_{y \in \mathbb{R}^n} \|Ay - b\|_2.$$

的**正则化方程组或法方程组**。

在 A 的列向量线性无关的条件下, $A^T A$ 对称正定, 可用平方根法求解。

求解最小二乘问题的正则化方法

1. 计算 $C = A^T A$, $d = A^T b$
2. 用平方根法计算 C 的 Cholesky 分解: $C = LL^T$
3. 求解三角方程组 $Ly = d$ 和 $L^T x = y$

计算 $A^T A$ 需使用足够的精度, 否则 A 的一些信息可能会丧失。如

$$A = \begin{bmatrix} 1 & 1 & 1 \\ \epsilon & 0 & 0 \\ 0 & \epsilon & 0 \\ 0 & 0 & \epsilon \end{bmatrix}$$

$$A^T A = \begin{bmatrix} 1 + \epsilon^2 & 1 & 1 \\ 1 & 1 + \epsilon^2 & 1 \\ 1 & 1 & 1 + \epsilon^2 \end{bmatrix}$$

正则化方程组 $A^T A x = A^T b$ 的解 x 可表示为

$$x = (A^T A)^{-1} A b$$

定义

$$A^\dagger = (A^T A)^{-1} A^T,$$

则最小二乘问题的解 x 可表示为

$$x = A^\dagger b,$$

而 $n \times m$ 矩阵 A^\dagger 正好是 $m \times n$ 矩阵 A 的 **Moore-Penrose 广义逆**。

定义 1. 若 $X \in \mathbb{R}^{n \times m}$ 满足

$$A X A = A, X A X = X, (A X)^T = A X, (X A)^T = X A,$$

则称 X 是 A 的 **Moore-Penrose 广义逆**，通常记为 A^\dagger 。

设 b 有扰动 δb ,

$$\Rightarrow \begin{cases} x \rightarrow \min \|b - A x\|_2 \\ x + \delta x \rightarrow \min \|(b + \delta b) - A x\|_2 \end{cases}$$

$$\Rightarrow \begin{cases} x = A^\dagger b \\ x + \delta x = A^\dagger(b + \delta b) = A^\dagger \tilde{b} \end{cases}$$

定理 5. 设 b_1, \tilde{b}_1 分别是 b, \tilde{b} 在 $\mathcal{R}(A)$ 上的正交投影，若 $b_1 \neq 0$ ，则

$$\frac{\|\delta x\|_2}{\|x\|_2} \leq \kappa_2(A) \frac{\|b_1 - \tilde{b}_1\|_2}{\|b_1\|_2},$$

其中 $\kappa_2(A) = \|A\|_2 \|A^\dagger\|_2$.

证明. 设 $b = b_1 + b_2$ 且 $b_2 \in \mathcal{R}(A)^\perp$ ，则 $A^T b_2 = 0$ 。于是

$$A^\dagger b = A^\dagger b_1 + A^\dagger b_2 = A^\dagger b_1 + (A^T A)^{-1} A^T b_2 = A^\dagger b_1.$$

同理可证

$$A^\dagger \tilde{b} = A^\dagger \tilde{b}_1.$$

从而

$$\|\delta x\|_2 = \|A^\dagger \tilde{b} - A^\dagger b\|_2 = \|A^\dagger(\tilde{b}_1 - b_1)\|_2 \leq \|A^\dagger\|_2 \|\tilde{b}_1 - b_1\|_2 \quad (5)$$

由 $Ax = b_1$ 得

$$\|b_1\|_2 \leq \|A\|_2 \|x\|_2$$

即

$$\frac{1}{\|x\|_2} \leq \|A\|_2 \frac{1}{\|b_1\|_2} \quad (6)$$

联立(5)和(6)可得定理结论。 \square

注 1. 值得注意的是:

1. 考虑 x 的相对误差时, 如果 b 有扰动, 那么只有它在 $\mathcal{R}(A)$ 上的投影 b_1 会对解产生影响。

2. 最小二乘问题的解的敏感性依赖于 $\kappa_2(A)$ 的大小, 称它为最小二乘问题的**条件数**。

若 $\kappa_2(A)$ 很大, 则称最小二乘问题是**病态**的; 否则称为**良态**的。

定理 6. 设 A 的列向量线性无关, 则 $\kappa_2(A)^2 = \kappa_2(A^T A)$ 。

证明. 一方面, 因为

$$\|A\|_2^2 = \lambda_{\max}(A^T A),$$

而

$$\|A^T A\|_2 = \sqrt{\lambda_{\max}((A^T A)^T (A^T A))} = \sqrt{\lambda_{\max}((A^T A)^2)} = \lambda_{\max}(A^T A),$$

故

$$\|A\|_2^2 = \|A^T A\|_2.$$

另一方面, 因

$$A^\dagger (A^\dagger)^T = (A^T A)^{-1} A^T ((A^T A)^{-1} A^T)^T = (A^T A)^{-1} A^T A (A^T A)^{-T} = (A^T A)^{-1}$$

故

$$\|A^\dagger\|_2^2 = \|A^\dagger (A^\dagger)^T\|_2^2 = \|(A^T A)^{-1}\|_2^2.$$

综上所述,

$$\kappa_2(A)^2 = \|A\|_2^2 \|A^\dagger\|_2^2 = \|A^T A\|_2^2 \|(A^T A)^{-1}\|_2^2 = \kappa_2(A^T A)$$

\square

注 2. 用正则化方法求解最小二乘问题的条件数是原问题的平方, 这使得求解过程增加了对舍入误差的敏感性。