

奇异值分解 (SVD, Singular Value Decomposition)

张晓平

2018 年 11 月 26 日

武汉大学数学与统计学院

Table of contents

1. SVD 介绍
2. SVD 算法
3. SVD 的几何解释
4. 应用
5. 减噪

SVD 介绍

设 A 为 $m \times n$ 矩阵。 A 的奇异值分解 (Singular Value Decomposition) 为

$$A = \mathbf{U} \Sigma \mathbf{V}^T, \quad (1)$$

其中 \mathbf{U} 为 $m \times m$ 的正交矩阵, \mathbf{V} 为 $n \times n$ 的正交矩阵, Σ 为主对角元非负的 $m \times n$ 对角阵, 其主对角元

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_p, \quad p \in \min\{m, n\}$$

称为 A 的奇异值 (singular value)。

将 U 和 V 按列分块, 即

$$U = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{pmatrix}, \quad V = \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \end{pmatrix},$$

则

- 由 V 的正交性可知(1)可表示为

$$AV = U\Sigma$$

即

$$A \begin{pmatrix} \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \end{pmatrix} = \begin{pmatrix} \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \end{pmatrix} \Sigma$$

亦即

$$A\mathbf{v}_j = \sigma_j \mathbf{u}_j, \quad j = 1, 2, \cdots, p. \quad (2)$$

- 对(1)转置可得

$$\mathbf{A}^T = \mathbf{V}\mathbf{\Sigma}^T \mathbf{U}^T$$

利用 \mathbf{U} 的正交性可得

$$\mathbf{A}^T \mathbf{U} = \mathbf{V}\mathbf{\Sigma}^T$$

即

$$\mathbf{A}^T \mathbf{u}_j = \sigma_j \mathbf{v}_j, \quad j = 1, 2, \dots, p. \quad (3)$$

- 对(1)转置可得

$$\mathbf{A}^T = \mathbf{V}\mathbf{\Sigma}^T \mathbf{U}^T$$

利用 \mathbf{U} 的正交性可得

$$\mathbf{A}^T \mathbf{U} = \mathbf{V}\mathbf{\Sigma}^T$$

即

$$\mathbf{A}^T \mathbf{u}_j = \sigma_j \mathbf{v}_j, \quad j = 1, 2, \dots, p. \quad (3)$$

对(2)两端左乘 \mathbf{A}^T ，再结合(3)可得

$$\mathbf{A}^T \mathbf{A} \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j,$$

由此可知， \mathbf{A} 的奇异值的平方为 $\mathbf{A}^T \mathbf{A}$ 的特征值；同理可证

$$\mathbf{A} \mathbf{A}^T \mathbf{u}_j = \sigma_j^2 \mathbf{u}_j.$$

SVD 算法

SVD 算法

显式对称 QR 方法

一种计算 \mathbf{A} 奇异值分解的方式是将对称 QR 算法应用于对称矩阵 $\mathbf{A}^T\mathbf{A}$ 以得到特征值分解 $\mathbf{A}^T\mathbf{A} = \mathbf{V}\Sigma\Sigma^T\mathbf{V}^T$ ，然后利用关系式(2)来计算 \mathbf{U} 。但
该方式涉及到 $\mathbf{A}^T\mathbf{A}$ 的计算，不实用。

SVD 算法

隐式对称 QR 方法

可以考虑将对称 QR 方法隐式地应用于 $A^T A$ 。

- 在特征值分解中，对称 QR 方法的第一步是利用 Householder 变换将矩阵约化为三对角形式；
- 而对于 SVD，我们可以利用 Householder 变换将矩阵 \mathbf{A} 约化为上两对角形式，即

$$\mathbf{U}_1^T \mathbf{A} \mathbf{V}_1 = \mathbf{B} = \begin{pmatrix} d_1 & f_1 & & & \\ & d_2 & f_2 & & \\ & & \ddots & \ddots & \\ & & & d_{n-1} & f_{n-1} \\ & & & & d_n \end{pmatrix}$$

以 5×4 矩阵

$$A = \begin{pmatrix} * & * & * & * \\ * & * & * & * \\ * & * & * & * \\ * & * & * & * \\ * & * & * & * \end{pmatrix}$$

为例，其具体过程如下：

隐式对称 QR 方法

1. 构造 $H_1 = \begin{pmatrix} \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \end{pmatrix}$ 使得

$$H_1 A = \begin{pmatrix} \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \\ \square & \square & \square & \square & \square \end{pmatrix} \begin{pmatrix} * & * & * & * \\ * & * & * & * \\ * & * & * & * \\ * & * & * & * \\ * & * & * & * \end{pmatrix} = \begin{pmatrix} * & * & * & * \\ & * & * & * \\ & * & * & * \\ & * & * & * \\ & * & * & * \end{pmatrix}$$

2. 构造 $H_2 = \begin{pmatrix} 1 & & & \\ & \square & \square & \square \\ & \square & \square & \square \\ & \square & \square & \square \end{pmatrix}$ 使得

$$H_1 A H_2^T = \begin{pmatrix} * & * & * & * \\ & * & * & * \\ & * & * & * \\ & * & * & * \\ & * & * & * \end{pmatrix} \begin{pmatrix} 1 & & & \\ & \square & \square & \square \\ & \square & \square & \square \\ & \square & \square & \square \end{pmatrix} = \begin{pmatrix} * & * & & \\ & * & * & * \\ & * & * & * \\ & * & * & * \\ & * & * & * \end{pmatrix}$$

3. 构造 $H_3 = \begin{pmatrix} 1 & & & & \\ & \square & \square & \square & \square \\ & \square & \square & \square & \square \\ & \square & \square & \square & \square \\ & \square & \square & \square & \square \end{pmatrix}$ 使得

$$\mathbf{H}_3 \mathbf{H}_1 \mathbf{A} \mathbf{H}_2^T = \begin{pmatrix} 1 & & & & \\ & \square & \square & \square & \square \\ & \square & \square & \square & \square \\ & \square & \square & \square & \square \\ & \square & \square & \square & \square \end{pmatrix} \begin{pmatrix} * & * & & & \\ & * & * & * & \\ & * & * & * & \\ & * & * & * & \\ & * & * & * & \end{pmatrix} = \begin{pmatrix} * & * & & & \\ & * & * & * & \\ & & * & * & \\ & & * & * & \\ & & * & * & \end{pmatrix}$$

4. 构造 $\mathbf{H}_4 = \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \square & \square \\ & & \square & \square \end{pmatrix}$ 使得

$$\mathbf{H}_3 \mathbf{H}_1 \mathbf{A} \mathbf{H}_2^T \mathbf{H}_4^T = \begin{pmatrix} * & * & & \\ & * & * & * \\ & & * & * \\ & & * & * \\ & & * & * \end{pmatrix} \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \square & \square \\ & & \square & \square \end{pmatrix} = \begin{pmatrix} * & * & & \\ & * & * & \\ & & * & * \\ & & * & * \\ & & * & * \end{pmatrix}$$

5. 构造 $H_5 = \begin{pmatrix} 1 & & & & \\ & 1 & & & \\ & & \square & \square & \square \\ & & \square & \square & \square \\ & & \square & \square & \square \end{pmatrix}$ 使得

$$\mathbf{H}_5 \mathbf{H}_3 \mathbf{H}_1 \mathbf{A} \mathbf{H}_2 \mathbf{H}_4 = \begin{pmatrix} 1 & & & & \\ & 1 & & & \\ & & \square & \square & \square \\ & & \square & \square & \square \\ & & \square & \square & \square \end{pmatrix} \begin{pmatrix} * & * & & & \\ & * & & & \\ & & * & & \\ & & * & * & \\ & & * & * & \\ & & * & * & \end{pmatrix} = \begin{pmatrix} * & * & & & \\ & * & & & \\ & & * & & \\ & & * & * & \\ & & & * & \\ & & & & * \end{pmatrix}$$

隐式对称 QR 方法

6. 构造 $H_6 = \begin{pmatrix} 1 & & & & \\ & 1 & & & \\ & & 1 & & \\ & & & \square & \square \\ & & & \square & \square \end{pmatrix}$ 使得

$$\begin{aligned} \mathbf{H}_6 \mathbf{H}_5 \mathbf{H}_3 \mathbf{H}_1 \mathbf{A} \mathbf{H}_2^T \mathbf{H}_4^T &= \begin{pmatrix} 1 & & & & \\ & 1 & & & \\ & & 1 & & \\ & & & \square & \square \\ & & & \square & \square \end{pmatrix} \begin{pmatrix} * & * & & & \\ & * & * & & \\ & & * & * & \\ & & & * & * \\ & & & & * \end{pmatrix} \\ &= \begin{pmatrix} * & * & & & \\ & * & * & & \\ & & * & * & \\ & & & * & * \\ & & & & * \end{pmatrix} \end{aligned}$$

记

$$\boldsymbol{U}_1^T = \boldsymbol{H}_6 \boldsymbol{H}_5 \boldsymbol{H}_3 \boldsymbol{H}_1, \quad \boldsymbol{V}_1 = \boldsymbol{H}_2^T \boldsymbol{H}_4^T,$$

即

$$\boldsymbol{U}_1 = \boldsymbol{H}_1 \boldsymbol{H}_3 \boldsymbol{H}_5 \boldsymbol{H}_6, \quad \boldsymbol{V}_1 = \boldsymbol{H}_2 \boldsymbol{H}_4$$

记

$$\mathbf{U}_1^T = \mathbf{H}_6 \mathbf{H}_5 \mathbf{H}_3 \mathbf{H}_1, \quad \mathbf{V}_1 = \mathbf{H}_2^T \mathbf{H}_4^T,$$

即

$$\mathbf{U}_1 = \mathbf{H}_1 \mathbf{H}_3 \mathbf{H}_5 \mathbf{H}_6, \quad \mathbf{V}_1 = \mathbf{H}_2 \mathbf{H}_4$$

注意: $\mathbf{T} = \mathbf{B}^T \mathbf{B} =$
$$\begin{pmatrix} \triangle & \triangle & & & \\ \triangle & \triangle & \triangle & & \\ & \triangle & \triangle & \triangle & \\ & & \triangle & \triangle & \triangle \\ & & & \triangle & \triangle \end{pmatrix}$$
 为对称的三对角阵。

由于 T 的计算量不大，我们可以将对称 QR 方法直接应用于 T 。但我们也可以通过在每一个迭代步执行以下步骤将对称 QR 方法隐式地用于 T 。

1. 对 $T - \mu I$ (其中 μ 为 Wilkinson 位移) 确定 Givens 行旋转 G_1^T , 这只需计算 T 的第一列中的前两个元素 $t_{11} = d_1^2$ 和 $t_{21} = d_1 f_1$ 。

$$G_1^T (T - \mu I) e_1 = \begin{pmatrix} \square & \square & & & \\ \square & \square & & & \\ & & 1 & & \\ & & & 1 & \\ & & & & 1 \end{pmatrix} \begin{pmatrix} \Delta - \mu \\ \Delta \\ 0 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} * \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

2. 将 G_1 作为列旋转作用到 B 的第一、二列得 $B_1 = BG_1$

$$BG_1 = \begin{pmatrix} * & * & & \\ & * & * & \\ & & * & * \\ & & & * \end{pmatrix} \begin{pmatrix} \square & \square & & \\ \square & \square & & \\ & & 1 & \\ & & & 1 \\ & & & & 1 \end{pmatrix} = \begin{pmatrix} * & * & & \\ + & * & * & \\ & & * & * \\ & & & * \end{pmatrix}$$

3. 构造 \tilde{G}_1 使得

$$\tilde{G}_1^T B G_1 = \begin{pmatrix} \square & \square & & & \\ \square & \square & & & \\ & & 1 & & \\ & & & 1 & \\ & & & & 1 \end{pmatrix} \begin{pmatrix} * & * & & & \\ + & * & * & & \\ & & * & * & \\ & & & * & * \\ & & & & * \end{pmatrix} = \begin{pmatrix} * & * & + & & \\ 0 & * & * & & \\ & & * & * & \\ & & & * & * \\ & & & & * \end{pmatrix}$$

4. 构造 G_2 使得

$$\tilde{G}_1^T B G_1 G_2 = \begin{pmatrix} * & * & + & & \\ & * & * & & \\ & & * & * & \\ & & & * & * \\ & & & & * \end{pmatrix} \begin{pmatrix} 1 & & & & \\ & \square & \square & & \\ & \square & \square & & \\ & & & 1 & \\ & & & & 1 \end{pmatrix} = \begin{pmatrix} * & * & 0 & & \\ & * & * & & \\ & & + & * & * \\ & & & * & * \\ & & & & * \end{pmatrix}$$

5. 构造 $\tilde{\mathbf{G}}_2$ 使得

$$\tilde{\mathbf{G}}_2^T \tilde{\mathbf{G}}_1^T \mathbf{B} \mathbf{G}_1 \mathbf{G}_2 = \begin{pmatrix} 1 & & & \\ & \square & \square & \\ & \square & \square & \\ & & & 1 \\ & & & & 1 \end{pmatrix} \begin{pmatrix} * & * & & \\ & * & * & \\ & + & * & * \\ & & * & * \end{pmatrix} = \begin{pmatrix} * & * & & \\ & * & * & + \\ & 0 & * & * \\ & & & * \end{pmatrix}$$

6. 构造 G_3 使得

$$\tilde{G}_2^T \tilde{G}_1^T B G_1 G_2 G_3 = \begin{pmatrix} * & * & & \\ & * & * & + \\ & & * & * \\ & & & * \end{pmatrix} \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \square & \square \\ & & \square & \square \end{pmatrix} = \begin{pmatrix} * & * & & \\ & * & * & 0 \\ & & * & * \\ & & + & * \end{pmatrix}$$

7. 构造 \tilde{G}_3 使得

$$\tilde{G}_3^T \tilde{G}_2^T \tilde{G}_1^T B G_1 G_2 G_3 = \begin{pmatrix} 1 & & & \\ & 1 & & \\ & & \square & \square \\ & & \square & \square \\ & & & 1 \end{pmatrix} \begin{pmatrix} * & * & & \\ & * & * & \\ & & * & * \\ & & + & * \end{pmatrix} = \begin{pmatrix} * & * & & \\ & * & * & \\ & & * & * \\ & & & * \end{pmatrix}$$

综上，令 $\tilde{\mathbf{G}} = \tilde{\mathbf{G}}_1 \tilde{\mathbf{G}}_2 \tilde{\mathbf{G}}_3$ 和 $\mathbf{G} = \mathbf{G}_1 \mathbf{G}_2 \mathbf{G}_3$ ，则

$$\tilde{\mathbf{G}}^T \mathbf{B} \mathbf{G} = \tilde{\mathbf{B}}$$

即

$$\mathbf{G}^T \mathbf{T} \mathbf{G} = \mathbf{G}^T \mathbf{B}^T \mathbf{B} \mathbf{G} = (\mathbf{G}^T \mathbf{B}^T \tilde{\mathbf{G}})(\tilde{\mathbf{G}}^T \mathbf{B} \mathbf{G}) = \tilde{\mathbf{B}}^T \tilde{\mathbf{B}} = \tilde{\mathbf{T}}.$$

至此 \mathbf{B}_6 又变成了上两对角矩阵，从而 $\tilde{\mathbf{T}}$ 为三对角阵。

SVD 的几何解释

SVD 的几何解释

线性变换的几何解释

SVD 的几何解释

$$Mx = x', \quad \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$




图 1: 对角阵

SVD 的几何解释

$$Mx = x', \quad \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$





图 2: 对称矩阵: 几何解释不直观

SVD 的几何解释

$$MGx = x', \quad \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} \cos \frac{\pi}{4} & -\sin \frac{\pi}{4} \\ \sin \frac{\pi}{4} & \cos \frac{\pi}{4} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$



SVD 的几何解释

因 M 为对称矩阵，其特征值分解可表示为

$$MV = V\Lambda, \quad \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} \cos \frac{\pi}{4} & -\sin \frac{\pi}{4} \\ \sin \frac{\pi}{4} & \cos \frac{\pi}{4} \end{pmatrix} = \begin{pmatrix} \cos \frac{\pi}{4} & -\sin \frac{\pi}{4} \\ \sin \frac{\pi}{4} & \cos \frac{\pi}{4} \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$


于是

$$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} \cos \frac{\pi}{4} & -\sin \frac{\pi}{4} \\ \sin \frac{\pi}{4} & \cos \frac{\pi}{4} \end{pmatrix} \mathbf{x} = \begin{pmatrix} \cos \frac{\pi}{4} & -\sin \frac{\pi}{4} \\ \sin \frac{\pi}{4} & \cos \frac{\pi}{4} \end{pmatrix} \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} \mathbf{x}$$

这说明对 \mathbf{x} 先逆时针旋转 45° ，再左乘 M ，等价于：先对 \mathbf{x} 沿横轴方向拉伸 3 倍，再逆时针旋转 45° 。


SVD 的几何解释

$$Mx = x', \quad \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$




SVD 的几何解释

$$MG\mathbf{x} = \mathbf{x}', \quad \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \cos \frac{\pi}{6} & -\sin \frac{\pi}{6} \\ \sin \frac{\pi}{6} & \cos \frac{\pi}{6} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$




SVD 的几何解释

$$MG\mathbf{x} = \mathbf{x}', \quad \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \cos \frac{\pi}{3} & -\sin \frac{\pi}{3} \\ \sin \frac{\pi}{3} & \cos \frac{\pi}{3} \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$



SVD 的几何解释

$$MGx = x', \quad \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} \cos 58.28^\circ & -\sin 58.28^\circ \\ \sin 58.28^\circ & \cos 58.28^\circ \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} x' \\ y' \end{pmatrix}$$



SVD 的几何解释

2×2 矩阵奇异值分解的几何解释为：对任何 2×2 矩阵，我们总是可以将一个正交网格变换到另一个正交网格。

SVD 的几何解释





图 3: $v_1 \perp v_2, \|v_1\| = \|v_2\| = 1, Mv_1 \perp Mv_2$

SVD 的几何解释



记 $\mathbf{u}_1, \mathbf{u}_2$ 分别为 $M\mathbf{v}_1, M\mathbf{v}_2$ 方向的单位向量, $M\mathbf{v}_1, M\mathbf{v}_2$ 的长度 σ_1, σ_2 称为 M 的奇异值。

SVD 的几何解释

$$M\boldsymbol{v}_1 = \sigma_1 \boldsymbol{u}_1$$

$$M\boldsymbol{v}_2 = \sigma_2 \boldsymbol{u}_2.$$

因 $\boldsymbol{v}_1 \perp \boldsymbol{v}_2$, 故 $\forall \boldsymbol{x} \in \mathbb{R}^2$

$$\boldsymbol{x} = (\boldsymbol{v}_1^T \boldsymbol{x}) \boldsymbol{v}_1 + (\boldsymbol{v}_2^T \boldsymbol{x}) \boldsymbol{v}_2$$

从而有

$$M\boldsymbol{x} = (\boldsymbol{v}_1^T \boldsymbol{x}) M\boldsymbol{v}_1 + (\boldsymbol{v}_2^T \boldsymbol{x}) M\boldsymbol{v}_2$$

即

$$M\boldsymbol{x} = (\boldsymbol{v}_1^T \boldsymbol{x}) \sigma_1 \boldsymbol{u}_1 + (\boldsymbol{v}_2^T \boldsymbol{x}) \sigma_2 \boldsymbol{u}_2$$

亦即

$$M\boldsymbol{x} = \boldsymbol{u}_1 \sigma_1 \boldsymbol{v}_1^T \boldsymbol{x} + \boldsymbol{u}_2 \sigma_2 \boldsymbol{v}_2^T \boldsymbol{x}$$

由 \boldsymbol{x} 的任意性可知

$$M = \boldsymbol{u}_1 \sigma_1 \boldsymbol{v}_1^T + \boldsymbol{u}_2 \sigma_2 \boldsymbol{v}_2^T$$

此即


$$M = U\Sigma V^T.$$

SVD 的几何解释

This shows how to decompose the matrix \mathbf{M} into the product of three matrices: \mathbf{V} describes an orthonormal basis in the domain, and \mathbf{U} describes an orthonormal basis in the co-domain, and Σ describes how much the vectors in \mathbf{V} are stretched to give the vectors in \mathbf{U} .

SVD 的几何解释

$$M = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix}, \quad M = u_1 \sigma_1 v_1^T.$$



应用

应用

数据压缩




图 4: 15 × 25 grey image




图 5: Only three types of columns in this image

[illegible]

通过计算可发现 M 仅有 3 个非零奇异值，即

$$\sigma_1 = 14.72, \quad \sigma_2 = 5.22, \quad \sigma_3 = 3.31.$$

故 M 的奇异值分解可表示为


$$M = \mathbf{u}_1 \sigma_1 \mathbf{v}_1^T + \mathbf{u}_2 \sigma_2 \mathbf{v}_2^T + \mathbf{u}_3 \sigma_3 \mathbf{v}_3^T.$$

表示矩阵时，

- 原形式需要保存 375 个元素
- SVD 只需保存 $3 \times 15 + 3 \times 25 + 3 = 123$ 个元素

也就是说，奇异值分解可消除矩阵中的冗余。

减燥



通过计算可发现 \mathbf{M} 仅有 3 个非零奇异值，即

$$\sigma_1 = 14.15$$

$$\sigma_2 = 4.67$$

$$\sigma_3 = 3.00$$

$$\sigma_4 = 0.21$$

$$\sigma_5 = 0.19$$


$$\vdots$$

$$\sigma_{15} = 0.05$$


$$\mathbf{M} \approx \mathbf{u}_1 \sigma_1 \mathbf{v}_1^T + \mathbf{u}_2 \sigma_2 \mathbf{v}_2^T + \mathbf{u}_3 \sigma_3 \mathbf{v}_3^T.$$

Noisy image

Improved image



减燥 数据分析



$$\begin{pmatrix} -1.03 & 0.74 & -0.02 & 0.51 & -1.31 & 0.99 & 0.69 & -0.12 & -0.72 & 1.11 \\ -2.23 & 1.61 & -0.02 & 0.88 & -2.39 & 2.02 & 1.62 & -0.35 & -1.67 & 2.46 \end{pmatrix}$$
$$\sigma_1 = 6.04, \quad \sigma_2 = 0.22$$

